

INSTITUTO DE COMPUTAÇÃO

PROJETO 1:

**PROCESSAMENTO DE
LINGUAGEM NATURAL 2026**

CGGJL

**CAIO MELLONI
GABRIEL LORHAN R. DOURADO
GEORGE HENRIQUE DE LIMA SÁ
JOÃO VITOR GONÇALVES OLIVEIRA
LUCAS GUARNIERI**

Definições

Entidade	▼	%	% casos	▼
Patient			100%	
Symptom			84%	
Finding			89%	
History			48%	
Exam			91%	
ExamResult			66%	
Diagnosis			91%	
Medication			62%	
Treatment			84%	
AnatomicalSite			84%	
Outcome			73%	


Aresta	▼	%	Origem → Destino
`HAS_SYMPTOM`			Patient → Symptom
`HAS_HISTORY`			Patient → History
`UNDERWENT_EXAM`			Patient → Exam
`HAS_RESULT`			Exam → ExamResult
`REVEALS`			Exam \ Treatment → Finding
`HAS_FINDING`			Patient → Finding
`SUPPORTS`			Symptom \ Finding \ ExamResult \ History → Diagnosis
`DIAGNOSED_WITH`			Patient → Diagnosis
`TREATED_WITH`			Patient \ Diagnosis → Treatment \ Medication
`LOCATED_IN`			Symptom \ Finding \ Treatment → AnatomicalSite
`HAS_OUTCOME`			Patient → Outcome
`REVISES`			Diagnosis → Diagnosis

POS tagging

Nós (substantivos)

Arestas (verbos)

Atributos (adjetivos)



Patient

UNDERWENT_EXAM

Computed
tomography

REVEALS

Cystic lesion

LOCATED_IN

Stomach

Onde o erra

O bloco foi delimitado corretamente, mas o tipo errado

heart rate → **AnatomicalSite** deveria ser um sinal vital, não um órgão
heart rate → AnatomicalSite ·

PMC4782471_01 → **heart failure** “she continued to deteriorate with heart failure and ongoing sepsis”
PMC4782471_01 → “she continued to deteriorate with heart failure and ongoing sepsis”

heart failure → **AnatomicalSite** é um **Diagnosis**
PMC7086412_01 → “diagnostic for diabetes based on criteria developed by the American Diabetes Association”

the American Diabetes Association → **Diagnosis** é o nome de uma instituição
PMC7718649_01 → “the patient was admitted to fever ward of Sino-French New City Branch”

fever ward → **Symptom** é a ala do hospital
PMC8627357_01 → “following the removal of the first chest tube”
(6 ocorrências no mesmo caso)

chest tube → **AnatomicalSite** é um dispositivo, um **Treatment**

É difícil de distinguir um verbo de um modificador no particípio


PMC10521634_01 - “The colonoscopy showed extensive colitis and was classified as a grade...”

um bloco só → **Exame:** “the colonoscopy showed extensive colitis”
Um bloco só → Exame: “the colonoscopy showed extensive colitis”


deveria ser → **Exame** → **“colonoscopy”** → **REVEALS** → **Finding “extensive colitis”**
Deveria ser → Exame “colonoscopy” → REVEALS → Finding “extensive colitis”

Por que acontece. **showed** tem forma de particípio, e a gramática aceita particípio como modificador — foi justamente essa permissão que salvou *contrast enhanced computed tomography*. As duas regras de reparo só cobrem o verbo depois de pronome relativo (*which revealed*) e depois de auxiliar (*was discharged*). Verbo em *-ed* abrindo a oração escapa das duas.


NORMALIZAÇÃO



Do relato clínico ao grafo



Por Trás da Normalização



Construção das Relações



11 tipos de entidades



IDs e relações validados



Evidências e offsets



CSV + impacto + Mermaid

Dr. Silva
Médico Silva

Doutor Silva

Mesmo conceito
≠ mesmo evento

Exame: Hemograma - 10/Out

Exame: Hemograma - 15/Out

Eventos Separados

Resultado



32
nós



42
arestas



Diagnóstico

Estruturalmente válido, mas ainda não totalmente correto semanticamente.



Negações

Dificuldade em identificar e tratar negações no texto.



Offsets

Desalinhamentos nos offsets das entidades.



Relações incorretas

Algumas relações foram atribuídas de forma inadequada.



Falsos positivos


Extração de entidades e relações que não são relevantes.




Conclusão

A normalização reduz variações e duplicatas, mas a qualidade do grafo também depende da extração e do contexto.


Resultado



TOKENIZAÇÃO



Por que a tokenização é difícil?



6cm x 9cm



EUS-FNA





CA 19-9



(Fig 1)







56 CASOS
PROCESSADOS

32.835
TOKENS


12,476.5ng/ml



NUMBER: 12,476.5

UNIT: ng/mL

Remoção de stop-words



Objetivo

Avaliar o impacto da implementação da remoção de stop words

Condição	Onde a remoção ocorre	Proteção aplicada?
BASELINE	nunca	-
NAIVE_UNPROTECTED	no case_text , antes da extração	não
GUARDED_GLOBAL	no case_text , antes da extração	sim
GUARDED_LABEL	só no label final, depois da extração	sim

Ambiente de avaliação e ferramentas

- **Extração usando Regex e léxico fechado**
- **NLTK, spaCy**

Resultado agregado

Condição	Lista	polarity_changed	Nós perdidos	Nós ganhos	Arestas perdidas	Arestas ganhas
GUARDED_GLOBAL	custom_clinical	0	641	389	664	463
GUARDED_GLOBAL	nltk_stopwords	0	638	387	662	462
GUARDED_GLOBAL	spacy_stopwords	0	640	388	663	462
GUARDED_LABEL	custom_clinical	0	494	492	539	537
GUARDED_LABEL	nltk_stopwords	0	486	485	536	536
GUARDED_LABEL	spacy_stopwords	0	492	490	538	536
NAIVE_UNPROTECTED	custom_clinical	0	641	389	664	463
NAIVE_UNPROTECTED	nltk_stopwords	14	649	398	672	472
NAIVE_UNPROTECTED	spacy_stopwords	21	651	399	675	474

NAIVE_UNPROTECTED × spaCy

condição	label	polarity
BASELINE	no progression of anemia and improvement in inflammatory markers	absent
NAIVE_UNPROTECTED × spaCy	progression anemia improvement inflammatory markers	present


condição	label	polarity
BASELINE	recurrence	absent
NAIVE_UNPROTECTED × spaCy	recurrence	present

Dicionários, tesauros e ontologias: função e funcionamento

Função e funcionamento

O que faz: liga cada menção extraída do texto a um conceito de vocabulário controlado, com código estável.

- Conceito casado → nó Concept + aresta SAME_AS
- Sem casamento → menção continua como nó normal (cobertura parcial esperada)
- Casamento em 3 níveis, do mais rígido ao mais flexível: exato → mais longo (multi-palavra) → aproximado (erro de digitação)



Duas fontes de vocabulário:

- MeSH (NLM) — pronto, 31 mil conceitos, filtrado por categoria (doença, droga, exame, tratamento)
- Gazetteer próprio de AnatomicalSite — construído do zero por nós

Curadoria do dicionário

- Pesquisa manual de termos anatômicos comuns (SEER/NCI, SUNY Lumen Learning)
- Seleção dos ~50 conceitos relevantes ao domínio clínico
- Código interno próprio (ANAT001, ANAT002, ...)
- Sinônimos escritos "à mão" – mapa explícito, não regra automática (stomach ↔ gastric)

Desafios:

- Procura de referências
- Decidir granularidade: incluir forearm, mas até onde? (extensor digitorum?)
- Sem validação externa

Desafios

Ambiguidade:

- Exemplo: "anemia" → D029502 (Anemia, Hypoplastic, Congenital) ou D029503 (Anemia, Diamond-Blackfan)?

Match genérico:

- "contrast enhanced computed tomography" → Tomography

Siglas:

- "CT" não é sinônimo oficial de Tomography, X-Ray Computed no MeSH

Falso positivo por similaridade em strings curtas:

- Fuzzy match: "had" ≈ "head", "one" ≈ "bone", "fear" ≈ "ear" — todos com 85,7% de similaridade