INSTITUTO DE COMPUTAÇÃO

PROJETO 2:

PROCESSAMENTO DE LINGUAGEM NATURAL 2026

CGGJL

CAIO MELLONI

GABRIEL LORHAN R. DOURADO

GEORGE HENRIQUE DE LIMA SÁ

JOÃO VITOR GONÇALVES OLIVEIRA

LUCAS GUARNIERI

https://github.com/caiomelloni/PNL-CGGJL

Do relato clínico ao grafo

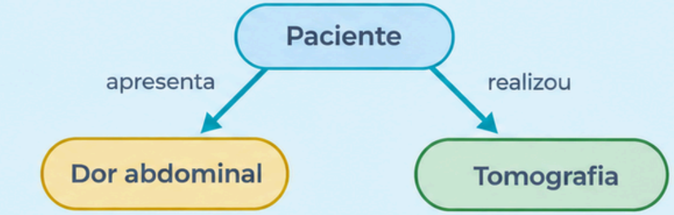
Relatos clínicos do MultiCaRe contêm informações sobre pacientes, sintomas, exames e diagnósticos.

Texto clínico

A paciente apresentou dor abdominal e realizou uma tomografia.

Exemplo ilustrativo

Grafo de conhecimento



Minha contribuição

Base comum

Leitura, palavras, frases e posições no texto.

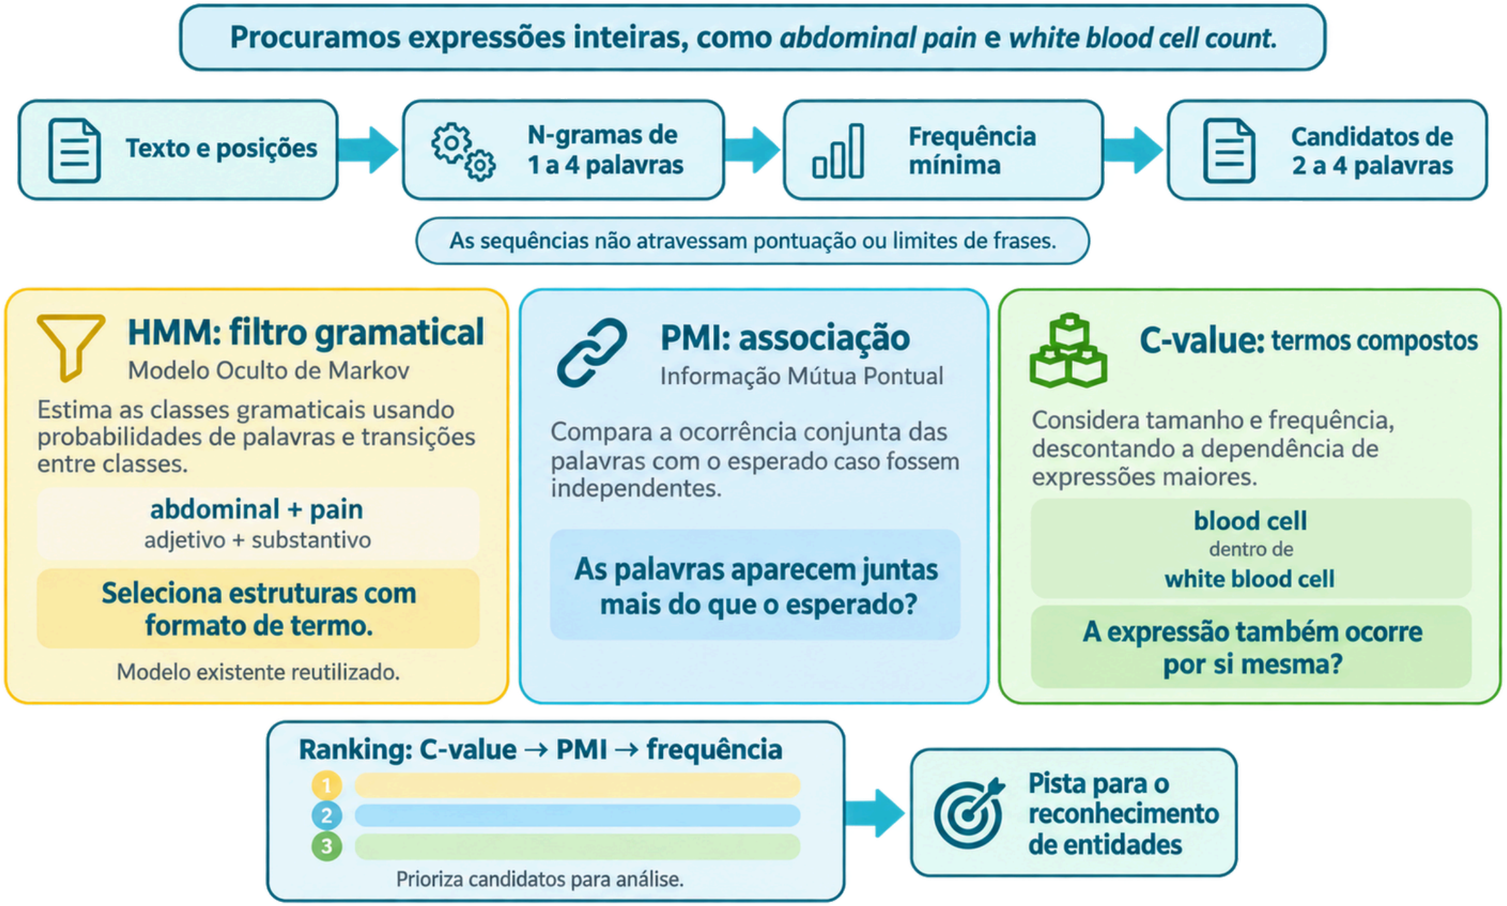
Termos compostos

Descoberta e ordenação de expressões candidatas.

Montagem

Menções e relações transformadas em nós e arestas.

Do relato clínico ao grafo



Do relato clínico ao grafo

Experimento na amostra de desenvolvimento do MultiCaRe.

56 relatos disponíveis − **3 reservados para evaliação provisória** = **53 relatos processados**

600 expressões candidatas

De 2 a 4 palavras, frequência mínima de 2 ocorrências e filtro gramatical.

Expressão	Ocorrências
physical examination	19
computed tomography	14
abdominal pain	13

Ocorrências no conjunto de 53 relatos.

Comparação com o MeSH

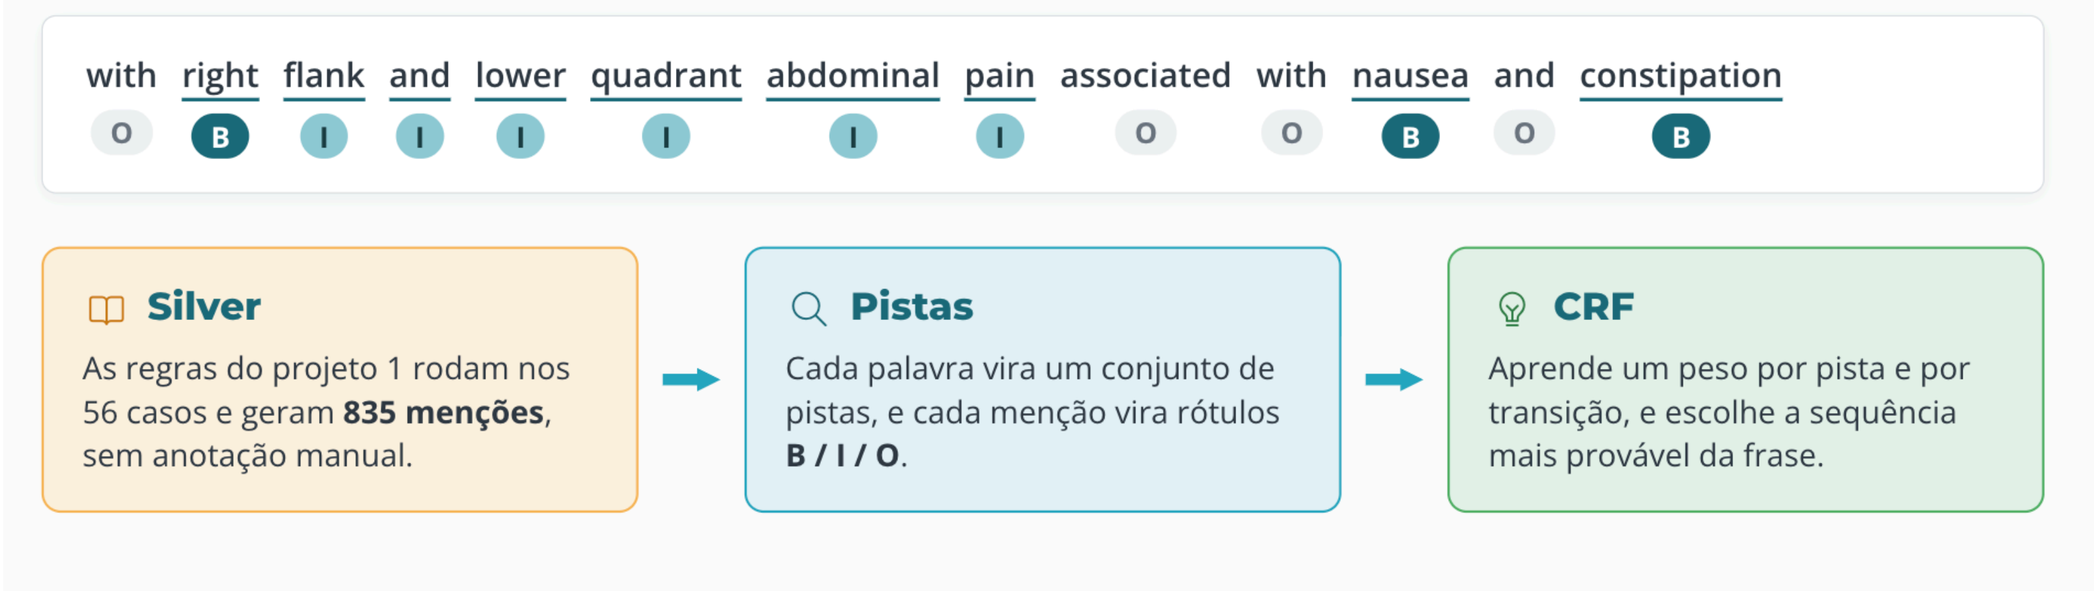
MeSH: Medical Subject Headings, um vocabulário controlado da área biomédica.
O gazetteer associa termos a códigos desse vocabulário.

20 dos 100 primeiros
Candidatos com correspondência na lista utilizada.

Correspondência lexical não é taxa de acerto.

Fronteiras com CRF

Cada palavra recebe um rótulo: B começa uma entidade, I continua, O fica de fora. O que não é marcado aqui nunca vira nó no grafo.



Limitações

- poucos dados
- treino baseado em regras pré-existentes
- treino baseado em regras pré-existentes

Regressão Logística

TIPAGEM DE ENTIDADES:
DICIONÁRIO + REGRESSÃO LOGÍSTICA

MENÇÃO DO CRF

DICIONÁRIO DO PROJETO 1:

- Procura corespondência do termo dentro do dicionário já implementado

Não Achou?

TF-IDF DE N-GRAMAS: TEXTO ➤ SCORE

- TF: frequência do termo na menção
- IDF: raridade no treino
- Score: TF x IDF
- Retorna vetor normalizado com scores

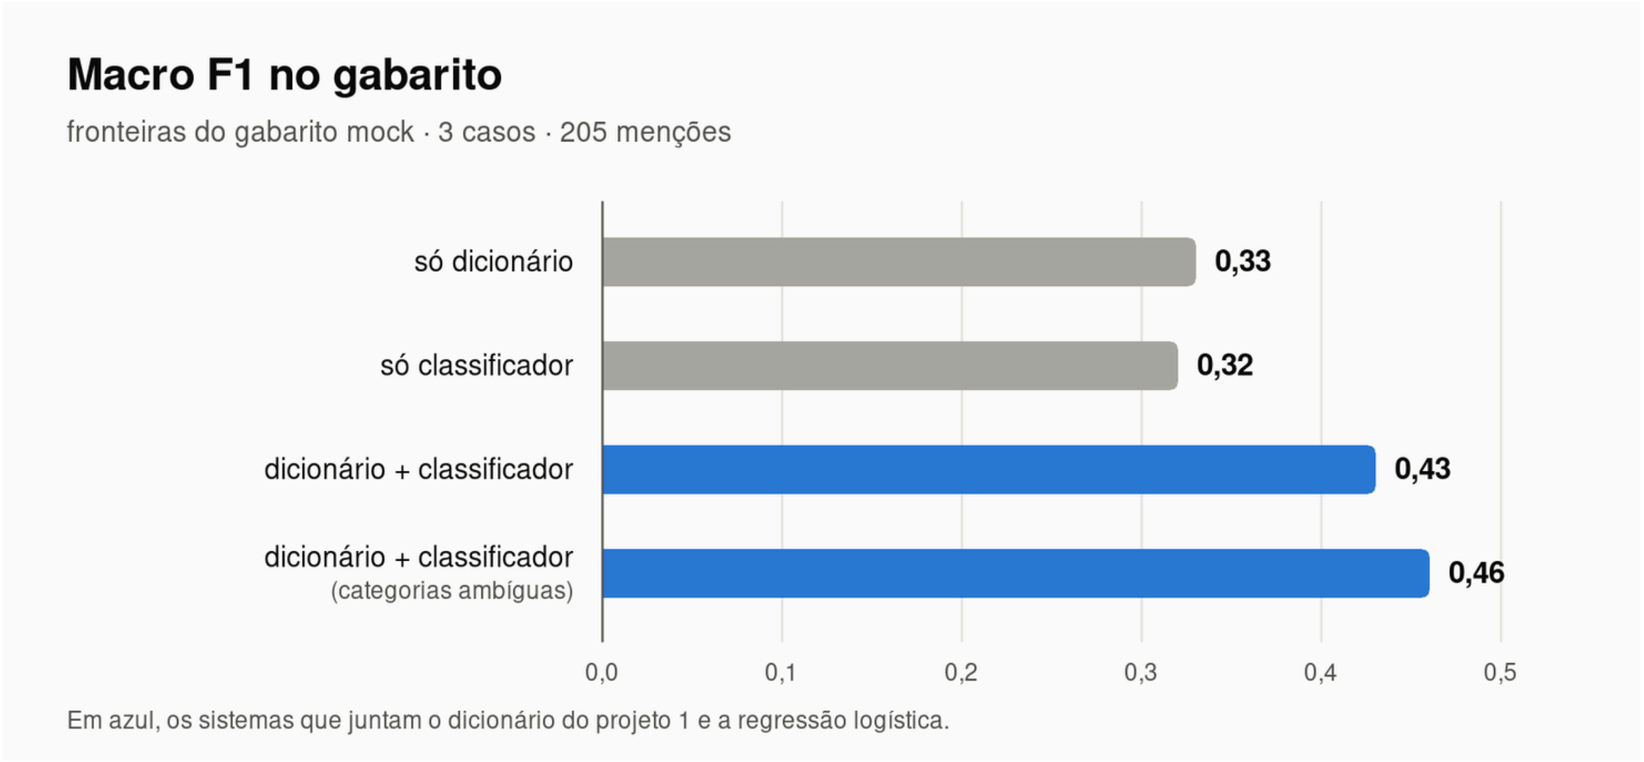
N-GRAMAS: Score calculado para conjunto de letras, conjunto de palavras e palavras vizinhas

REGRESSÃO LOGISTICA

- Vetor score x matriz de pesos aprendidos
- Vetor com pontuações por tipos ➤ Vetor de probabilidades (softmax)
- Limiar e argmax determinam o tipo

Treino no silver (regras do projeto 1) · scikit-learn

Resultados



Resultados obtidos com dados de teste

Relações

Método

- Par com 'patient' → relação fixa
- Par entre outras entidades → classificador de N-gramas
- TF-IDF do texto entre as entidades
- Tipo + distância + ordem
- Regressão logística e SVM linear

Resultados

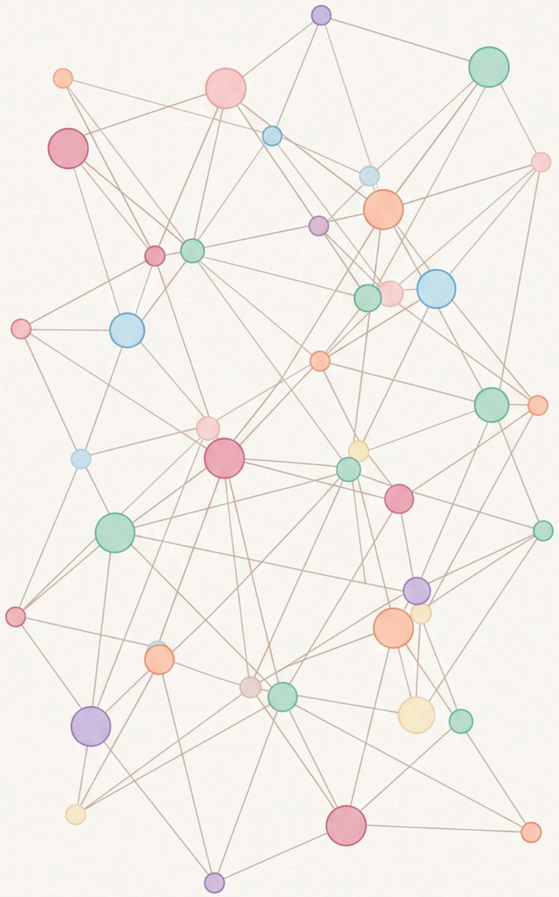
Modelo	N-grama	Split	macro-F1 (sem `NONE`)
LogisticRegression	1-1	val	0,691
LogisticRegression	1-3	val	0,688
LinearSVC	1-1	val	**0,761**
LinearSVC	1-3	val	0,757
LogisticRegression	1-1 (vencedora)	test	0,480

Resultados

Relação	Precision (val)	Recall (val)	Suporte (val)	Suporte (test)
HAS_RESULT	0,41	1,00	20	14
LOCATED_IN	0,88	1,00	15	13
REVEALS	0,39	1,00	5	3
SUPPORTS	—	—	**0**	2
NONE	1,00	0,86	275	523

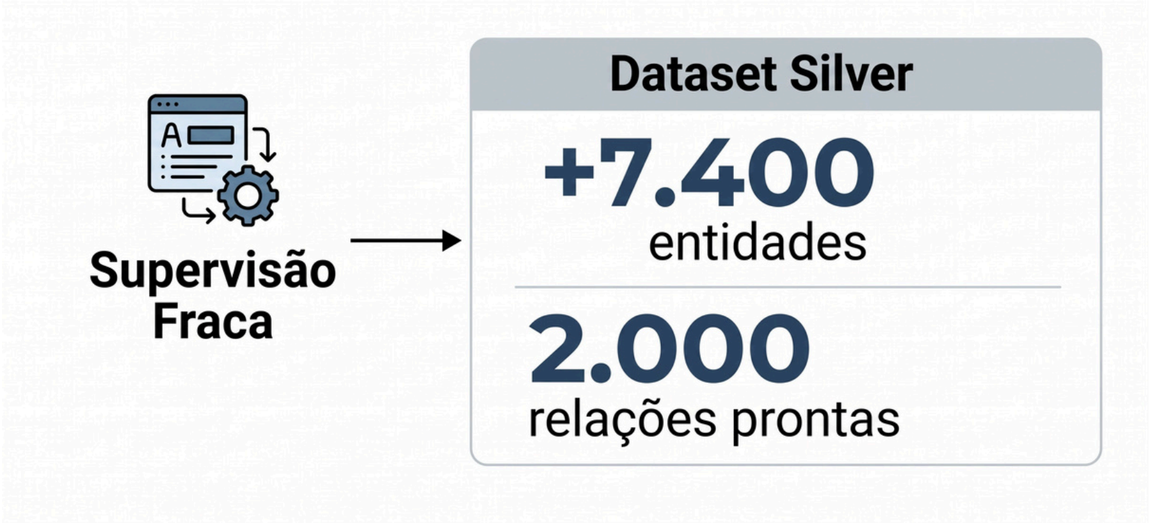
Dados, Avaliação e Montagem

SUPERVISÃO FRACA, BENCHMARKING OFICIAL E CONSOLIDAÇÃO DO GRAFO DE CONHECIMENTO



Infraestrutura de Dados & Supervisão Fraca





Métricas

RÉGUA DE AVALIAÇÃO OFICIAL

Métrica A: Entidades

Precision, Recall e F1 (Casamento Exato e Overlap)



Métrica B: Tipos Clínicos

Acurácia Global, Macro-F1

Matriz de Confusão



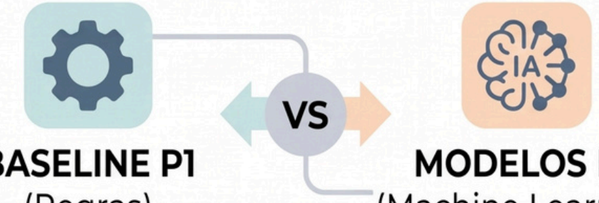
Métrica C: Relações & Negação

F1 de Arestas

F1 Dedicado de Negação (polarity=absent)



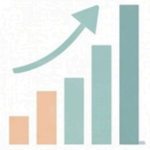
CONFRONTO EXPERIMENTAL



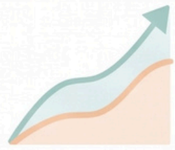
BASELINE P1
(Regras)

MODELOS P2
(Machine Learning)

CÁLCULO DE DELTAS & GANHOS



Deltas Absolutos (Δ)



Ganhos Percentuais (%)



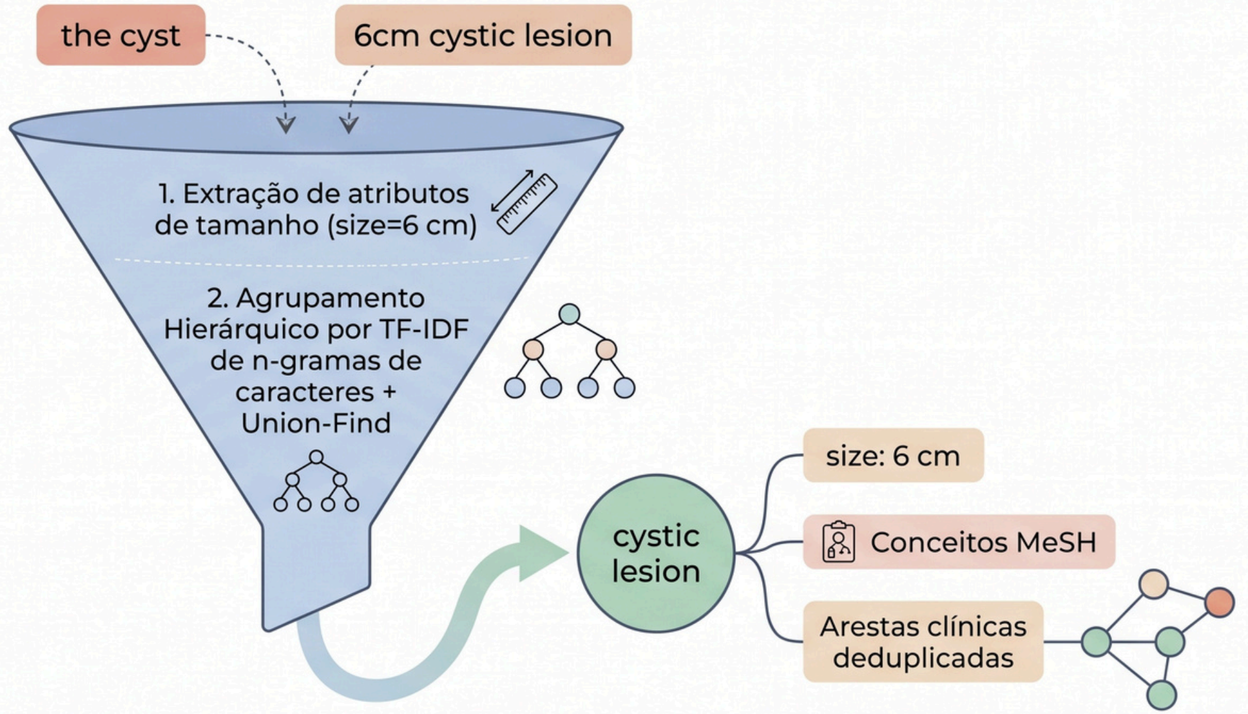
Relatórios Automáticos

Montagem do Grafo Final & Resultados

O PROBLEMA
Múltiplas menções no texto dispersas

PROCESSO
(MOTOR DE MONTAGEM)

A SOLUÇÃO
Princípio "Um nó por coisa"



RESULTADOS
MÉTRICAS DO PROCESSO

- **56** de **56** Casos Montados (100% sucesso)
- **1.393** Nós e **833** Arestas consolidadas
- **23** Testes Unitários automatizados

OBRIGADO!